

概率论公式整理

1、排列与组合公式

$$P_m^n = \frac{m!}{(m-n)!} \quad \text{从 } m \text{ 个人中挑出 } n \text{ 个人进行排列的可能数。}$$

$$C_m^n = \frac{m!}{n!(m-n)!} \quad \text{从 } m \text{ 个人中挑出 } n \text{ 个人进行组合的可能数。}$$

2、加法和乘法原理

加法原理（两种方法均能完成此事） $m+n$

某件事由两种方法来完成，第一种方法可由 m 种方法完成，第二种方法可由 n 种方法来完成，则这件事可由 $m+n$ 种方法来完成。

乘法原理（两个步骤分别不能完成这件事） $m \times n$

某件事由两个步骤来完成，第一个步骤可由 m 种方法完成，第二个步骤可由 n 种方法来完成，则这件事可由 $m \times n$ 种方法来完成。

3、随机试验和随机事件

如果一个试验在相同条件下可以重复进行，而每次试验的可能结果不止一个，但在进行一次试验之前却不能断言它出现哪个结果，则称这种试验为随机试验。

试验的可能结果称为随机事件。

4、基本事件、样本空间和事件

在一个试验下，不管事件有多少个，总可以从其中找出这样一组事件，它具有如下性质：

①每进行一次试验，必须发生且只能发生这一组中的一个事件；

②任何事件，都是由这一组中的部分事件组成的。

这样一组事件中的每一个事件称为基本事件，用 ω 来表示。

基本事件的全体，称为试验的样本空间，用 Ω 表示。

一个事件就是由 Ω 中的部分点（基本事件 ω ）组成的集合。通常用大写字母 $A, B, C, \dots$ 表示事件，它们是 Ω 的子集。

Ω 为必然事件， $\emptyset$ 为不可能事件。

不可能事件（ $\emptyset$ ）的概率为零，而概率为零的事件不一定是不可事件；同理，必然事件（ Ω ）的概率为 1，而概率为 1 的事件也不一定是必然事件。

5、事件的关系与运算

①关系:

如果事件 A 的组成部分也是事件 B 的组成部分, (A 发生必有事件 B 发生):

$$A \subset B$$

如果同时有 $A \subset B$, $B \supset A$, 则称事件 A 与事件 B 等价, 或称 A 等于 B : $A=B$ 。

A 、 B 中至少有一个发生的事件: $A \cup B$, 或者 $A+B$ 。

属于 A 而不属于 B 的部分所构成的事件, 称为 A 与 B 的差, 记为 $A-B$, 也可表示为 $A-AB$ 或者 $A\bar{B}$, 它表示 A 发生而 B 不发生的事件。

A 、 B 同时发生: $A \cap B$, 或者 AB 。 $A \cap B = \emptyset$, 则表示 A 与 B 不可能同时发生, 称事件 A 与事件 B 互不相容或者互斥。基本事件是互不相容的。

$\Omega - A$ 称为事件 A 的逆事件, 或称 A 的对立事件, 记为 $\bar{A}$ 。它表示 A 不发生的事件。互斥未必对立。

②运算:

结合率: $A(BC) = (AB)C$ $A \cup (B \cap C) = (A \cup B) \cap C$

分配率: $(AB) \cup C = (A \cup C)(B \cup C)$ $(A \cup B) \cap C = (AC) \cup (BC)$

德摩根率: $\overline{\bigcap_{i=1}^{\infty} A_i} = \bigcup_{i=1}^{\infty} \bar{A}_i$ $\overline{A \cup B} = \bar{A} \cap \bar{B}$, $\overline{A \cap B} = \bar{A} \cup \bar{B}$

6、概率的公理化定义

设 Ω 为样本空间, A 为事件, 对每一个事件 A 都有一个实数 $P(A)$, 若满足下列三个条件:

1° $0 \leq P(A) \leq 1$,

2° $P(\Omega) = 1$

3° 对于两两互不相容的事件 $A_1, A_2, \dots$ 有

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

常称为可列 (完全) 可加性。

则称 $P(A)$ 为事件 A 的概率。

7、古典概型

$$1^\circ \quad \Omega = \{\omega_1, \omega_2, \dots, \omega_n\},$$

$$2^\circ \quad P(\omega_1) = P(\omega_2) = \dots = P(\omega_n) = \frac{1}{n}.$$

设任一事件 A ，它是由 $\omega_1, \omega_2, \dots, \omega_m$ 组成的，则有

$$P(A) = \{(\omega_1) \cup (\omega_2) \cup \dots \cup (\omega_m)\} = P(\omega_1) + P(\omega_2) + \dots + P(\omega_m)$$

$$= \frac{m}{n} = \frac{A \text{ 所包含的基本事件数}}{\text{基本事件总数}}$$

<https://blog.csdn.net/xdy1120>

8、几何概型

若随机试验的结果为无限不可数并且每个结果出现的可能性均匀，同时样本空间中的每一个基本事件可以使用一个有界区域来描述，则称此随机试验为几何概型。对任一事件 A ，

$$P(A) = \frac{L(A)}{L(\Omega)}。 \text{其中 } L \text{ 为几何度量（长度、面积、体积）。}$$

9、加法公式

$$P(A+B) = P(A) + P(B) - P(AB)$$

$$\text{当 } P(AB) = 0 \text{ 时, } P(A+B) = P(A) + P(B)$$

10、减法公式

$$P(A-B) = P(A) - P(AB)$$

$$\text{当 } B \subset A \text{ 时, } P(A-B) = P(A) - P(B)$$

$$\text{当 } A = \Omega \text{ 时, } P(\overline{B}) = 1 - P(B)$$

11、条件概率

定义 设 A 、 B 是两个事件，且 $P(A) > 0$ ，则称 $\frac{P(AB)}{P(A)}$ 为事件 A 发生条件下，事

件 B 发生的条件概率，记为 $P(B/A) = \frac{P(AB)}{P(A)}$ 。

条件概率是概率的一种，所有概率的性质都适合于条件概率。

$$\text{例如 } P(\Omega/B) = 1 \Rightarrow P(\overline{B}/A) = 1 - P(B/A)$$

12、乘法公式

$$\text{乘法公式: } P(AB) = P(A)P(B/A)$$

更一般地，对事件 $A_1, A_2, \dots, A_n$ ，若 $P(A_1 A_2 \dots A_{n-1}) > 0$ ，则有

$$P(A_1 A_2 \dots A_n) = P(A_1)P(A_2 | A_1)P(A_3 | A_1 A_2) \dots P(A_n | A_1 A_2 \dots A_{n-1})。$$

13、独立性

①两个事件的独立性

设事件 A 、 B 满足 $P(AB) = P(A)P(B)$ ，则称事件 A 、 B 是相互独立的。

若事件 A 、 B 相互独立，且 $P(A) > 0$ ，则有

$$P(B|A) = \frac{P(AB)}{P(A)} = \frac{P(A)P(B)}{P(A)} = P(B)$$

若事件 A 、 B 相互独立，则可得到 $\bar{A}$ 与 B 、 A 与 $\bar{B}$ 、 $\bar{A}$ 与 $\bar{B}$ 也都相互独立。

必然事件 Ω 和不可能事件 $\emptyset$ 与任何事件都相互独立。

$\emptyset$ 与任何事件都互斥。

②多个事件的独立性

设 ABC 是三个事件，如果满足两两独立的条件，

$$P(AB) = P(A)P(B); P(BC) = P(B)P(C); P(CA) = P(C)P(A)$$

并且同时满足 $P(ABC) = P(A)P(B)P(C)$

那么 A 、 B 、 C 相互独立。

对于 n 个事件类似。

<https://blog.csdn.net/xdy1120>

14、全概率公式

设事件 $B_1, B_2, \dots, B_n$ 满足

1° $B_1, B_2, \dots, B_n$ 两两互不相容, $P(B_i) > 0 (i = 1, 2, \dots, n)$,

$$2^\circ A \subset \bigcup_{i=1}^n B_i,$$

则有

$$P(A) = P(B_1)P(A|B_1) + P(B_2)P(A|B_2) + \dots + P(B_n)P(A|B_n)。$$

15、贝叶斯公式

设事件 $B_1, B_2, \dots, B_n$ 及 A 满足

1° $B_1, B_2, \dots, B_n$ 两两互不相容, $P(B_i) > 0, i = 1, 2, \dots, n,$

2° $A \subset \bigcup_{i=1}^n B_i, P(A) > 0,$

则

$$P(B_i / A) = \frac{P(B_i)P(A / B_i)}{\sum_{j=1}^n P(B_j)P(A / B_j)}, i=1, 2, \dots, n.$$

此公式即为贝叶斯公式。

$P(B_i), (i = 1, 2, \dots, n),$ 通常叫先验概率。 $P(B_i / A), (i = 1, 2, \dots, n),$ 通常称为后验概率。贝叶斯公式反映了“因果”的概率规律, 并作出了“由果溯因”的推断。
<https://blog.csdn.net/xdy1120>

16、伯努利概率模型

我们作了 n 次试验, 且满足

- ◆ 每次试验只有两种可能结果, A 发生或 A 不发生;
- ◆ n 次试验是重复进行的, 即 A 发生的概率每次均一样;
- ◆ 每次试验是独立的, 即每次试验 A 发生与否与其他次试验 A 发生与否是互不影响的。

这种试验称为伯努利概型, 或称为 n 重伯努利试验。

用 p 表示每次试验 A 发生的概率, 则 $\bar{A}$ 发生的概率为 $1 - p = q$, 用 $P_n(k)$ 表

示 n 重伯努利试验中 A 出现 $k (0 \leq k \leq n)$ 次的概率,

$$P_n(k) = C_n^k p^k q^{n-k}, k = 0, 1, 2, \dots, n. \quad \text{https://blog.csdn.net/xdy1120}$$

17、离散型随机变量的分布律

设离散型随机变量 X 的可能取值为 $x_k (k=1, 2, \dots)$ 且取各个值的概率，即事件 $(X=x_k)$ 的概率为

$$P(X=x_k)=p_k, \quad k=1, 2, \dots,$$

则称上式为离散型随机变量 X 的概率分布或分布律。有时也用分布列的形式给出：

$$\begin{array}{c|c} X & x_1, x_2, \dots, x_k, \dots \\ \hline P(X=x_k) & p_1, p_2, \dots, p_k, \dots \end{array}.$$

显然分布律应满足下列条件：

$$(1) \quad p_k \geq 0, \quad k=1, 2, \dots, \quad (2) \quad \sum_{k=1}^{\infty} p_k = 1.$$

18、连续型随机变量的分布密度

设 $F(x)$ 是随机变量 X 的分布函数，若存在非负函数 $f(x)$ ，对任意实数 x ，有

$$F(x) = \int_{-\infty}^x f(x)dx,$$

则称 X 为连续型随机变量。 $f(x)$ 称为 X 的概率密度函数或密度函数，简称概率密度。

密度函数具有下面 4 个性质：

$$1^\circ \quad f(x) \geq 0.$$

$$2^\circ \quad \int_{-\infty}^{+\infty} f(x)dx = 1.$$

19、离散与连续随机变量的关系

$$P(X=x) \approx P(x < X \leq x+dx) \approx f(x)dx$$

积分元 $f(x)dx$ 在连续型随机变量理论中所起的作用与 $P(X=x_k)=p_k$ 在离散型随机变量理论中所起的作用相类似。

20、分布函数

设 X 为随机变量， x 是任意实数，则函数

$$F(x) = P(X \leq x)$$

称为随机变量 X 的分布函数，本质上是一个累积函数。

$P(a < X \leq b) = F(b) - F(a)$ 可以得到 X 落入区间 $(a, b]$ 的概率。分布

函数 $F(x)$ 表示随机变量落入区间 $(-\infty, x]$ 内的概率。

分布函数具有如下性质：

1° $0 \leq F(x) \leq 1, \quad -\infty < x < +\infty;$

2° $F(x)$ 是单调不减的函数，即 $x_1 < x_2$ 时，有 $F(x_1) \leq F(x_2)$ ；

3° $F(-\infty) = \lim_{x \rightarrow -\infty} F(x) = 0, \quad F(+\infty) = \lim_{x \rightarrow +\infty} F(x) = 1;$

4° $F(x+0) = F(x)$ ，即 $F(x)$ 是右连续的；

5° $P(X = x) = F(x) - F(x-0)。$

对于离散型随机变量， $F(x) = \sum_{x_k \leq x} p_k;$

对于连续型随机变量， $F(x) = \int_{-\infty}^x f(x)dx。$

<https://blog.csdn.net/xdy1120>

21、0-1 分布

$$P(X=1)=p, \quad P(X=0)=q$$

22、二项分布

在 n 重贝努里试验中，设事件 A 发生的概率为 p 。事件 A 发生的次数是随机变量，设为 X ，则 X 可能取值为 $0, 1, 2, \dots, n$ 。

$$P(X = k) = P_n(k) = C_n^k p^k q^{n-k}, \quad \text{其中}$$

$$q = 1 - p, 0 < p < 1, k = 0, 1, 2, \dots, n,$$

则称随机变量 X 服从参数为 n, p 的二项分布。记为

$$X \sim B(n, p)。$$

当 $n = 1$ 时， $P(X = k) = p^k q^{1-k}$ ， $k = 0, 1$ ，这就是（0-1）分布，所以（0-1）分布是二项分布的特例。

23、泊松分布

设随机变量 X 的分布律为

$$P(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad \lambda > 0, \quad k = 0, 1, 2, \dots,$$

则称随机变量 X 服从参数为 λ 的泊松分布，记为 $X \sim \pi(\lambda)$ 或者 $P(\lambda)$ 。

泊松分布为二项分布的极限分布（ $np = \lambda, n \rightarrow \infty$ ）。

24、超几何分布

$$P(X = k) = \frac{C_M^k \bullet C_{N-M}^{n-k}}{C_N^n}, \quad k = 0, 1, 2, \dots, l$$

$$l = \min(M, n)$$

随机变量 X 服从参数为 n, N, M 的超几何分布，记为 $H(n, N, M)$ 。

25、几何分布

$$P(X = k) = q^{k-1} p, k = 1, 2, 3, \dots, \text{其中 } p \geq 0, q = 1 - p。$$

随机变量 X 服从参数为 p 的几何分布，记为 $G(p)$ 。

26、均匀分布

设随机变量 X 的值只落在 $[a, b]$ 内，其密度函数 $f(x)$ 在 $[a, b]$ 上为常数 $\frac{1}{b-a}$ ，即

$$f(x) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b \\ 0, & \text{其他,} \end{cases}$$

则称随机变量 X 在 $[a, b]$ 上服从均匀分布，记为 $X \sim U(a, b)$ 。
分布函数为

$$F(x) = \int_{-\infty}^x f(x) dx = \begin{cases} 0, & x < a, \\ \frac{x-a}{b-a}, & a \leq x \leq b \\ 1, & x > b. \end{cases}$$

当 $a \leq x_1 < x_2 \leq b$ 时， X 落在区间 (x_1, x_2) 内的概率为

$$P(x_1 < X < x_2) = \frac{x_2 - x_1}{b - a}。$$

<https://blog.csdn.net/xdy1120>

27、指数分布

$$f(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0, \end{cases}$$

其中 $\lambda > 0$ ，则称随机变量 X 服从参数为 λ 的指数分布。
 X 的分布函数为

$$F(x) = \begin{cases} 1 - e^{-\lambda x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

记住积分公式：

$$\int_0^{+\infty} x^n e^{-x} dx = n!$$

<https://blog.csdn.net/xdy1120>

28、正太分布

设随机变量 X 的密度函数为

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad -\infty < x < +\infty,$$

其中 μ 、 $\sigma > 0$ 为常数, 则称随机变量 X 服从参数为 μ 、 σ

的正态分布或高斯 (Gauss) 分布, 记为 $X \sim N(\mu, \sigma^2)$ 。

$f(x)$ 具有如下性质:

1° $f(x)$ 的图形是关于 $x = \mu$ 对称的;

2° 当 $x = \mu$ 时, $f(\mu) = \frac{1}{\sqrt{2\pi}\sigma}$ 为最大值;

若 $X \sim N(\mu, \sigma^2)$, 则 X 的分布函数为

$$F(x) = \frac{1}{\sqrt{2\pi}\sigma} \int_{-\infty}^x e^{-\frac{t^2}{2\sigma^2}} dt \quad \dots$$

参数 $\mu = 0$ 、 $\sigma = 1$ 时的正态分布称为标准正态分布, 记为

$X \sim N(0, 1)$, 其密度函数记为

$$\varphi(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad -\infty < x < +\infty,$$

分布函数为

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt.$$

$\Phi(x)$ 是不可求积函数, 其函数值, 已编制成表可供查用。

$\Phi(-x) = 1 - \Phi(x)$ 且 $\Phi(0) = \frac{1}{2}$ 。

如果 $X \sim N(\mu, \sigma^2)$, 则 $\frac{X - \mu}{\sigma} \sim N(0, 1)$ 。

$$P(x_1 < X \leq x_2) = \Phi\left(\frac{x_2 - \mu}{\sigma}\right) - \Phi\left(\frac{x_1 - \mu}{\sigma}\right).$$

29、分位数

下分位表: $P(X \leq \mu_\alpha) = \alpha$;

上分位表: $P(X > \mu_\alpha) = \alpha$ 。

30、函数分布

离散型

已知 X 的分布列为

$$\begin{array}{c|c} X & x_1, x_2, \dots, x_n, \dots \\ \hline P(X = x_i) & p_1, p_2, \dots, p_n, \dots \end{array},$$

$Y = g(X)$ 的分布列 ($y_i = g(x_i)$ 互不相等) 如下:

$$\begin{array}{c|c} Y & g(x_1), g(x_2), \dots, g(x_n), \dots \\ \hline P(Y = y_i) & p_1, p_2, \dots, p_n, \dots \end{array},$$

若有某些 $g(x_i)$ 相等, 则应将对应的 p_i 相加作为 $g(x_i)$ 的概率。

连续型

先利用 X 的概率密度 $f_X(x)$ 写出 Y 的分布函数 $F_Y(y) = P(g(X) \leq y)$, 再利用变上下限积分的求导公式求出 $f_Y(y)$ 。

31、联合分布

离散型

如果二维随机向量 $\xi = (X, Y)$ 的所有可能取值为至多可列个有序对 (x, y) ，则称 ξ 为离散型随机量。

设 $\xi = (X, Y)$ 的所有可能取值为 $(x_i, y_j) (i, j = 1, 2, \dots)$ ，且事件 $\{\xi = (x_i, y_j)\}$ 的概率为 p_{ij} ，称

$$P\{(X, Y) = (x_i, y_j)\} = p_{ij} (i, j = 1, 2, \dots)$$

为 $\xi = (X, Y)$ 的分布律或称为 X 和 Y 的联合分布律。联合分布有时也用下面的概率分布表来表示：

$\begin{matrix} Y \\ X \end{matrix}$	y_1	y_2	„	y_j	„
x_1	p_{11}	p_{12}	„	p_{1j}	„
x_2	p_{21}	p_{22}	„	p_{2j}	„
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
x_i	p_{i1}		„	p_{ij}	„
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$

这里 p_{ij} 具有下面两个性质：

(1) $p_{ij} \geq 0$ ($i, j = 1, 2, \dots$)；

(2) $\sum_i \sum_j p_{ij} = 1$.

<https://blog.csdn.net/xdy1120>

连续型

对于二维随机向量 $\xi = (X, Y)$ ，如果存在非负函数

$f(x, y) (-\infty < x < +\infty, -\infty < y < +\infty)$ ，使对任意一个其邻边分别平行于坐标轴的矩形区域 D ，即 $D = \{(X, Y) \mid a < x < b, c < y < d\}$ 有

$$P\{(X, Y) \in D\} = \iint_D f(x, y) dx dy,$$

则称 ξ 为连续型随机向量；并称 $f(x, y)$ 为 $\xi = (X, Y)$ 的分布密度或称为 X 和 Y 的联合分布密度。

分布密度 $f(x, y)$ 具有下面两个性质：

(1) $f(x, y) \geq 0$;

(2) $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f(x, y) dx dy = 1.$ <https://blog.csdn.net/xdy1120>

32、二维随机变量的本质

$$\xi(X = x, Y = y) = \xi(X = x \cap Y = y)$$

33、联合分布函数

设 (X, Y) 为二维随机变量, 对于任意实数 x, y , 二元函数

$$F(x, y) = P\{X \leq x, Y \leq y\}$$

称为二维随机向量 (X, Y) 的分布函数, 或称为随机变量 X 和 Y 的联合分布函数。

分布函数是一个以全平面为其定义域, 以事件 $\{(\omega_1, \omega_2) | -\infty < X(\omega_1) \leq x, -\infty < Y(\omega_2) \leq y\}$ 的概率为函数值的一个实值函数。分布函数 $F(x, y)$ 具有以下的基本性质:

(1) $0 \leq F(x, y) \leq 1$;

(2) $F(x, y)$ 分别对 x 和 y 是非减的, 即
当 $x_2 > x_1$ 时, 有 $F(x_2, y) \geq F(x_1, y)$; 当 $y_2 > y_1$ 时, 有 $F(x, y_2) \geq F(x, y_1)$;

(3) $F(x, y)$ 分别对 x 和 y 是右连续的, 即

$$F(x, y) = F(x+0, y), F(x, y) = F(x, y+0);$$

(4) $F(-\infty, -\infty) = F(-\infty, y) = F(x, -\infty) = 0, F(+\infty, +\infty) = 1.$

(5) 对于 $x_1 < x_2, y_1 < y_2$,

$$F(x_2, y_2) - F(x_2, y_1) - F(x_1, y_2) + F(x_1, y_1) \geq 0. \text{pg.csdn.net/xdy1120}$$

34、离散型和连续型之间的关系

$$P(X = x, Y = y) \approx P(x < X \leq x + dx, y < Y \leq y + dy) \approx f(x, y)dx dy$$

35、边缘分布

离散型	X 的边缘分布为 $P_{i\bullet} = P(X = x_i) = \sum_j p_{ij} (i, j = 1, 2, \dots);$ Y 的边缘分布为 $P_{\bullet j} = P(Y = y_j) = \sum_i p_{ij} (i, j = 1, 2, \dots)。$
连续型	X 的边缘分布密度为 $f_X(x) = \int_{-\infty}^{+\infty} f(x, y) dy;$ Y 的边缘分布密度为 $f_Y(y) = \int_{-\infty}^{+\infty} f(x, y) dx.$
36、条件分布 离散型	在已知 $X=x_i$ 的条件下, Y 取值的条件分布为 $P(Y = y_j X = x_i) = \frac{p_{ij}}{p_{i\bullet}};$ 在已知 $Y=y_j$ 的条件下, X 取值的条件分布为 $P(X = x_i Y = y_j) = \frac{p_{ij}}{p_{\bullet j}},$
连续型	在已知 $Y=y$ 的条件下, X 的条件分布密度为 $f(x y) = \frac{f(x, y)}{f_Y(y)};$ 在已知 $X=x$ 的条件下, Y 的条件分布密度为 $f(y x) = \frac{f(x, y)}{f_X(x)}$

37、独立性

一般型	$F(X, Y) = F_X(x)F_Y(y)$
离散型	$P_{ij} = P_{i\bullet}P_{\bullet j}$ 有零不独立
连续型	$f(x, y) = f_X(x)f_Y(y)$ 直接判断，充要条件： ①可分离变量 ②正概率密度区间为矩形
二维正态分布	$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_1}{\sigma_1}\right)^2 - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \left(\frac{y-\mu_2}{\sigma_2}\right)^2\right]}$ $\rho = 0$ https://blog.csdn.net/xdy1120
随机变量的函数	若 $X_1, X_2, \dots, X_m, X_{m+1}, \dots, X_n$ 相互独立，h, g 为连续函数，则： $h(X_1, X_2, \dots, X_m)$ 和 $g(X_{m+1}, \dots, X_n)$ 相互独立。 特例：若 X 与 Y 独立，则：$h(X)$ 和 $g(Y)$ 独立。 例如：若 X 与 Y 独立，则：$3X+1$ 和 $5Y-2$ 独立。

38、二维均匀分布

设随机向量 (X, Y) 的分布密度函数为

$$f(x, y) = \begin{cases} \frac{1}{S_D} & (x, y) \in D \\ 0, & \text{其他} \end{cases}$$

其中 S_D 为区域 D 的面积，则称 (X, Y) 服从 D 上的均匀分布，记为 $(X, Y) \sim U(D)$ 。

例如图 3.1、图 3.2 和图 3.3。




图 3.1




图 3.2




图 3.3

<https://blog.csdn.net/xdy1120>

39、二维正太分布

设随机向量 (X, Y) 的分布密度函数为

$$f(x, y) = \frac{1}{2\pi\sigma_1\sigma_2\sqrt{1-\rho^2}} e^{-\frac{1}{2(1-\rho^2)}\left[\left(\frac{x-\mu_1}{\sigma_1}\right)^2 - \frac{2\rho(x-\mu_1)(y-\mu_2)}{\sigma_1\sigma_2} + \left(\frac{y-\mu_2}{\sigma_2}\right)^2\right]}$$

其中 $\mu_1, \mu_2, \sigma_1 > 0, \sigma_2 > 0, |\rho| < 1$ 是 5 个参数，则称 (X, Y) 服从二维正态分布，

记为 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ 。

由边缘密度的计算公式，可以推出二维正态分布的两个边缘分布仍为正态分布，

即 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$ 。

但是若 $X \sim N(\mu_1, \sigma_1^2), Y \sim N(\mu_2, \sigma_2^2)$ ， (X, Y) 未必是二维正态分布。

40、函数分布

$Z=X+Y$

根据定义计算： $F_Z(z) = P(Z \leq z) = P(X + Y \leq z)$

对于连续型， $f_z(z) = \int_{-\infty}^{+\infty} f(x, z-x)dx$

两个独立的正态分布的和仍为正态分布 $(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ 。

n 个相互独立的正态分布的线性组合，仍服从正态分布。

$$\mu = \sum_i C_i \mu_i, \quad \sigma^2 = \sum_i C_i^2 \sigma_i^2$$

$Z=\max, \min(X_1, X_2, \dots, X_n)$

若 $X_1, X_2 \dots X_n$ 相互独立，其分布函数分别为

$F_{x_1}(x), F_{x_2}(x) \dots F_{x_n}(x)$ ，则 $Z=\max, \min(X_1, X_2, \dots, X_n)$ 的分布函数为：

$$F_{\max}(x) = F_{x_1}(x) \bullet F_{x_2}(x) \dots F_{x_n}(x)$$

$$F_{\min}(x) = 1 - [1 - F_{x_1}(x)] \bullet [1 - F_{x_2}(x)] \dots [1 - F_{x_n}(x)]$$

χ^2 分布

设 n 个随机变量 $X_1, X_2, \dots, X_n$ 相互独立，且服从标准正态分布，可以证明它们的平方和

$$W = \sum_{i=1}^n X_i^2$$

的分布密度为

$$f(u) = \begin{cases} \frac{1}{2^{\frac{n}{2}} \Gamma\left(\frac{n}{2}\right)} u^{\frac{n}{2}-1} e^{-\frac{u}{2}} & u \geq 0, \\ 0, & u < 0. \end{cases}$$

我们称随机变量 W 服从自由度为 n 的 χ^2 分布，记为 $W \sim \chi^2(n)$ ，其中

$$\Gamma\left(\frac{n}{2}\right) = \int_0^{\infty} x^{\frac{n}{2}-1} e^{-x} dx$$

所谓自由度是指独立正态随机变量的个数，它是随机变量分布中的一个重要参数。

χ^2 分布满足可加性：设

$$Y_i \sim \chi^2(n_i),$$

则

$$Z = \sum_{i=1}^k Y_i \sim \chi^2(n_1 + n_2 + \dots + n_k).$$

t 分布	设 X, Y 是两个相互独立的随机变量，且 $X \sim N(0,1), Y \sim \chi^2(n),$ 可以证明函数 $T = \frac{X}{\sqrt{Y/n}}$ 的概率密度为 $f(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\sqrt{n\pi}\Gamma\left(\frac{n}{2}\right)} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} \quad (-\infty < t < +\infty).$ 我们称随机变量 T 服从自由度为 n 的 t 分布，记为 $T \sim t(n)$。 $t_{1-\alpha}(n) = -t_{\alpha}(n)$
F 分布	设 $X \sim \chi^2(n_1), Y \sim \chi^2(n_2)$，且 X 与 Y 独立，可以证明 $F = \frac{X/n_1}{Y/n_2}$ 的概率密度函数为 $f(y) = \begin{cases} \frac{\Gamma\left(\frac{n_1+n_2}{2}\right)}{\Gamma\left(\frac{n_1}{2}\right)\Gamma\left(\frac{n_2}{2}\right)} \left(\frac{n_1}{n_2}\right)^{\frac{n_1}{2}} y^{\frac{n_1}{2}-1} \left(1 + \frac{n_1}{n_2}y\right)^{-\frac{n_1+n_2}{2}}, & y \geq 0 \\ 0, & y < 0 \end{cases}$ 我们称随机变量 F 服从第一个自由度为 n_1，第二个自由度为 n_2 的 F 分布，记为 $F \sim f(n_1, n_2)$。 $F_{1-\alpha}(n_1, n_2) = \frac{1}{F_{\alpha}(n_2, n_1)}$

<https://blog.csdn.net/xdy1120>

41、随机变量的数字特征

(1) | 离散型 | 连续型

一 维 随 机 变 量 的 数 字 特 征	期望 期望就是平均值	设 X 是离散型随机变量,其分布律为 $P(X = x_k) = p_k$, $k=1, 2, \dots, n$, $E(X) = \sum_{k=1}^n x_k p_k$ (要求绝对收敛)	设 X 是连续型随机变量,其概率密度为 $f(x)$, $E(X) = \int_{-\infty}^{+\infty} x f(x) dx$ (要求绝对收敛)
	函数的期望	$Y=g(X)$ $E(Y) = \sum_{k=1}^n g(x_k) p_k$	$Y=g(X)$ $E(Y) = \int_{-\infty}^{+\infty} g(x) f(x) dx$
	方差 $D(X)=E[X-E(X)]^2$, 标准差 $\sigma(X)=\sqrt{D(X)}$,	$D(X) = \sum_k [x_k - E(X)]^2 p_k$	$D(X) = \int_{-\infty}^{+\infty} [x - E(X)]^2 f(x) dx$
	矩	①对于正整数 k,称随机变量 X 的 k 次幂的数学期望为 X 的 k 阶原点矩,记为 v_k,即 $v_k = E(X^k) = \sum_i x_i^k p_i,$ $k=1, 2, \dots$ ②对于正整数 k,称随机变量 X 与 $E(X)$ 差的 k 次幂的数学期望为 X 的 k 阶中心矩,记为 μ_k,即 $\mu_k = E(X - E(X))^k$ $= \sum_i (x_i - E(X))^k p_i,$ $k=1, 2, \dots$	①对于正整数 k,称随机变量 X 的 k 次幂的数学期望为 X 的 k 阶原点矩,记为 v_k,即 $v_k = E(X^k) = \int_{-\infty}^{+\infty} x^k f(x) dx,$ $k=1, 2, \dots$ ②对于正整数 k,称随机变量 X 与 $E(X)$ 差的 k 次幂的数学期望为 X 的 k 阶中心矩,记为 μ_k,即 $\mu_k = E(X - E(X))^k$ $= \int_{-\infty}^{+\infty} (x - E(X))^k f(x) dx,$ $k=1, 2, \dots$ https://blog.csdn.net/xdy1120

	切比雪夫不等式	设随机变量 X 具有数学期望 $E(X)=\mu$ ，方差 $D(X)=\sigma^2$ ，则对于任意正数 ε ，有下列切比雪夫不等式 $P(X-\mu \geq\varepsilon)\leq\frac{\sigma^2}{\varepsilon^2}$ 切比雪夫不等式给出了在未知 X 的分布的情况下，对概率 $P(X-\mu \geq\varepsilon)$ 的一种估计，它在理论上具有重要意义。	
(2) 期望的性质	(1) $E(C)=C$ (2) $E(CX)=CE(X)$ (3) $E(X+Y)=E(X)+E(Y)$ ， $E(\sum_{i=1}^n C_i X_i)=\sum_{i=1}^n C_i E(X_i)$ (4) $E(XY)=E(X)E(Y)$ ，充分条件： X 和 Y 独立； 充要条件： X 和 Y 不相关。		
(3) 方差的性质	(1) $D(C)=0$ ； $E(C)=C$ (2) $D(aX)=a^2D(X)$ ； $E(aX)=aE(X)$ (3) $D(aX+b)=a^2D(X)$ ； $E(aX+b)=aE(X)+b$ (4) $D(X)=E(X^2)-E^2(X)$ (5) $D(X\pm Y)=D(X)+D(Y)$ ，充分条件： X 和 Y 独立； 充要条件： X 和 Y 不相关。 $D(X\pm Y)=D(X)+D(Y)\pm2E[(X-E(X))(Y-E(Y))]$ ，无条件成立。 而 $E(X+Y)=E(X)+E(Y)$ ，无条件成立。		
(4) 常见分布的期望和方差		期望	方差
	0-1 分布 $B(1,p)$	p	$p(1-p)$
	二项分布 $B(n,p)$	np	$np(1-p)$
	泊松分布 $P(\lambda)$	λ	https://blog.csdn.net/xdy1120
	几何分布 $G(p)$	$\frac{1}{p}$	$\frac{1-p}{p^2}$
	超几何分布 $H(n,M,N)$	$\frac{nM}{N}$	$\frac{nM}{N}\left(1-\frac{M}{N}\right)\left(\frac{N-n}{N-1}\right)$
	均匀分布 $U(a,b)$	$\frac{a+b}{2}$	$\frac{(b-a)^2}{12}$
	指数分布 $e(\lambda)$	$\frac{1}{\lambda}$	https://blog.csdn.net/xdy1120 $\frac{1}{\lambda^2}$

(5) 二 维 随 机 变 量 的 数 字 特 征	正态分布 $N(\mu, \sigma^2)$	μ	σ^2
	χ^2 分布	n	2n
	t 分布	0	$\frac{n}{n-2}$ (n>2)
	期望	$E(X) = \sum_{i=1}^n x_i p_{i\bullet}$ $E(Y) = \sum_{j=1}^n y_j p_{\bullet j}$	$E(X) = \int_{-\infty}^{+\infty} x f_X(x) dx$ $E(Y) = \int_{-\infty}^{+\infty} y f_Y(y) dy$
	函数的期望	$E[G(X, Y)] =$ $\sum_i \sum_j G(x_i, y_j) p_{ij}$	$E[G(X, Y)] =$ $\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} G(x, y) f(x, y) dx dy$
	方差	$D(X) = \sum_i [x_i - E(X)]^2 p_{i\bullet}$ $D(Y) = \sum_j [y_j - E(Y)]^2 p_{\bullet j}$	$D(X) = \int_{-\infty}^{+\infty} [x - E(X)]^2 f_X(x) dx$ $D(Y) = \int_{-\infty}^{+\infty} [y - E(Y)]^2 f_Y(y) dy$
	协方差	对于随机变量 X 与 Y, 称它们的二阶混合中心矩 μ_{11} 为 X 与 Y 的协方差或相关矩, 记为 σ_{XY} 或 $\text{cov}(X, Y)$, 即 $\sigma_{XY} = \mu_{11} = E[(X - E(X))(Y - E(Y))].$ 与记号 σ_{XY} 相对应, X 与 Y 的方差 D(X) 与 D(Y) 也可分别记为 σ_{XX} 与 σ_{YY}。	

相关系数	对于随机变量 X 与 Y，如果 $D(X) > 0$, $D(Y) > 0$，则称 $\frac{\sigma_{XY}}{\sqrt{D(X)}\sqrt{D(Y)}}$ 为 X 与 Y 的相关系数，记作 ρ_{XY}（有时可简记为 ρ）。 $\rho \leq 1$，当 $\rho = 1$ 时，称 X 与 Y 完全相关：$P(X = aY + b) = 1$ 完全相关 $\begin{cases} \text{正相关, 当 } \rho = 1 \text{ 时 } (a > 0), \\ \text{负相关, 当 } \rho = -1 \text{ 时 } (a < 0), \end{cases}$ 而当 $\rho = 0$ 时，称 X 与 Y 不相关。 以下五个命题是等价的： ① $\rho_{XY} = 0$； ② $\text{cov}(X, Y) = 0$； ③ $E(XY) = E(X)E(Y)$； ④ $D(X+Y) = D(X) + D(Y)$； ⑤ $D(X-Y) = D(X) + D(Y)$。
协方差矩阵	$\begin{pmatrix} \sigma_{XX} & \sigma_{XY} \\ \sigma_{YX} & \sigma_{YY} \end{pmatrix}$
混合矩	对于随机变量 X 与 Y，如果有 $E(X^k Y^l)$ 存在，则称之为 X 与 Y 的 $k+l$ 阶混合原点矩，记为 ν_{kl}；$k+l$ 阶混合中心矩记为： $u_{kl} = E[(X - E(X))^k (Y - E(Y))^l]$

(6) 协方差的性质	(i) $\text{cov}(X, Y) = \text{cov}(Y, X)$； (ii) $\text{cov}(aX, bY) = ab \text{cov}(X, Y)$； (iii) $\text{cov}(X_1 + X_2, Y) = \text{cov}(X_1, Y) + \text{cov}(X_2, Y)$； (iv) $\text{cov}(X, Y) = E(XY) - E(X)E(Y)$。
(7) 独立和不相关	(i) 若随机变量 X 与 Y 相互独立，则 $\rho_{XY} = 0$；反之不真。 (ii) 若 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$， 则 X 与 Y 相互独立的充要条件是 X 和 Y 不相关。

42、大数定理和中心极限定理

(1) 大数定律 $\bar{X} \rightarrow \mu$	切比雪夫大数定律	设随机变量 $X_1, X_2, \dots$ 相互独立, 均具有有限方差, 且被同一常数 C 所界: $D(X_i) < C (i=1, 2, \dots)$, 则对于任意的正数 ε, 有 $\lim_{n \rightarrow \infty} P\left(\left \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n E(X_i)\right < \varepsilon\right) = 1.$ 特殊情形: 若 $X_1, X_2, \dots$ 具有相同的数学期望 $E(X_i) = \mu$, 则上式成为 $\lim_{n \rightarrow \infty} P\left(\left \frac{1}{n} \sum_{i=1}^n X_i - \mu\right < \varepsilon\right) = 1.$
	伯努利大数定律	设 μ 是 n 次独立试验中事件 A 发生的次数, p 是事件 A 在每次试验中发生的概率, 则对于任意的正数 ε, 有 $\lim_{n \rightarrow \infty} P\left(\left \frac{\mu}{n} - p\right < \varepsilon\right) = 1.$ 伯努利大数定律说明, 当试验次数 n 很大时, 事件 A 发生的频率与概率有较大判别的可能性很小, 即 $\lim_{n \rightarrow \infty} P\left(\left \frac{\mu}{n} - p\right \geq \varepsilon\right) = 0.$ 这就以严格的数学形式描述了频率的稳定性。
	辛钦大数定律	设 $X_1, X_2, \dots, X_n, \dots$ 是相互独立同分布的随机变量序列, 且 $E(X_k) = \mu$, 则对于任意的正数 ε 有 $\lim_{n \rightarrow \infty} P\left(\left \frac{1}{n} \sum_{i=1}^n X_i - \mu\right < \varepsilon\right) = 1.$ https://blog.csdn.net/xdy1120

(2) 中心极限定理 $\bar{X} \rightarrow N(\mu, \frac{\sigma^2}{n})$	列维-林德伯格定理	设随机变量 $X_1, X_2, \dots$ 相互独立, 服从同一分布, 且具有相同的数学期望和方差: $E(X_k) = \mu, D(X_k) = \sigma^2 \neq 0 (k=1, 2, \dots)$, 则随机变量 $Y_n = \frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma}$ 的分布函数 $F_n(x)$ 对任意的实数 x, 有 $\lim_{n \rightarrow \infty} F_n(x) = \lim_{n \rightarrow \infty} P\left\{\frac{\sum_{k=1}^n X_k - n\mu}{\sqrt{n}\sigma} \leq x\right\} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt.$ 此定理也称为独立同分布的中心极限定理。 https://blog.csdn.net/xdy1120
--	------------------	--

	棣莫弗-拉普拉斯定理	设随机变量 X_n 为具有参数 $n, p (0 < p < 1)$ 的二项分布, 则对于任意实数 x, 有 $= \lim_{n \rightarrow \infty} P \left\{ \frac{X_n - np}{\sqrt{np(1-p)}} \leq x \right\} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt.$
(3) 二项定理	若当 $N \rightarrow \infty$ 时, $\frac{M}{N} \rightarrow p (n, k \text{ 不变})$, 则 $\frac{C_M^k C_{N-M}^{n-k}}{C_N^n} \rightarrow C_n^k p^k (1-p)^{n-k} \quad (N \rightarrow \infty).$ 超几何分布的极限分布为二项分布。	
(4) 泊松定理	若当 $n \rightarrow \infty$ 时, $np \rightarrow \lambda > 0$, 则 $C_n^k p^k (1-p)^{n-k} \rightarrow \frac{\lambda^k}{k!} e^{-\lambda} \quad (n \rightarrow \infty).$ 其中 $k=0, 1, 2, \dots, n, \dots$. 二项分布的极限分布为泊松分布。	https://blog.csdn.net/xdy1120

43、样本及抽样分布

(1) 数理统计的基本概念	总体	在数理统计中, 常把被考察对象的某一个(或多个)指标的全体称为总体(或母体)。我们总是把总体看成一个具有分布的随机变量(或随机向量)。
	个体	总体中的每一个单元称为样品(或个体)。
	样本	我们把从总体中抽取的部分样品 $x_1, x_2, \dots, x_n$ 称为样本。样本中所含的样品数称为样本容量, 一般用 n 表示。在一般情况下, 总是把样本看成是 n 个相互独立的且与总体有相同分布的随机变量, 这样的样本称为简单随机样本。在泛指任一次抽取的结果时, $x_1, x_2, \dots, x_n$ 表示 n 个随机变量(样本); 在具体的一次抽取之后, $x_1, x_2, \dots, x_n$ 表示 n 个具体的数值(样本值)。我们称之为样本的两重性。
	样本函数和统计量	设 $x_1, x_2, \dots, x_n$ 为总体的一个样本, 称 $\varphi = \varphi(x_1, x_2, \dots, x_n)$ 为样本函数, 其中 φ 为一个连续函数。如果 φ 中不包含任何未知参数, 则称 $\varphi(x_1, x_2, \dots, x_n)$ 为一个统计量。

	常见统计量及其性质	样本均值 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$ 样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2.$ 样本标准差 $S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}.$ 样本 k 阶原点矩 $M_k = \frac{1}{n} \sum_{i=1}^n x_i^k, k=1,2,\dots.$ 样本 k 阶中心矩 $M'_k = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^k, k=2,3,\dots.$ $E(\bar{X}) = \mu, D(\bar{X}) = \frac{\sigma^2}{n},$ $E(S^2) = \sigma^2, E(S^{*2}) = \frac{n-1}{n} \sigma^2,$ 其中 $S^{*2} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$, 为二阶中心矩。
(2) 正态总体下的四大分布	正态分布	设 $x_1, x_2, \dots, x_n$ 为来自正态总体 $N(\mu, \sigma^2)$ 的一个样本, 则样本函数 $u \stackrel{\text{def}}{=} \frac{\bar{x} - \mu}{\sigma / \sqrt{n}} \sim N(0,1).$
	t 分布	设 $x_1, x_2, \dots, x_n$ 为来自正态总体 $N(\mu, \sigma^2)$ 的一个样本, 则样本函数 $t \stackrel{\text{def}}{=} \frac{\bar{x} - \mu}{s / \sqrt{n}} \sim t(n-1),$ 其中 $t(n-1)$ 表示自由度为 $n-1$ 的 t 分布。

χ^2 分布	设 $x_1, x_2, \dots, x_n$ 为来自正态总体 $N(\mu, \sigma^2)$ 的一个样本，则样本函数 $w \stackrel{\text{def}}{=} \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1),$ 其中 $\chi^2(n-1)$ 表示自由度为 $n-1$ 的 χ^2 分布。
F 分布	设 $x_1, x_2, \dots, x_{n_1}$ 为来自正态总体 $N(\mu, \sigma_1^2)$ 的一个样本，而 $y_1, y_2, \dots, y_{n_2}$ 为来自正态总体 $N(\mu, \sigma_2^2)$ 的一个样本，则样本函数 $F \stackrel{\text{def}}{=} \frac{S_1^2 / \sigma_1^2}{S_2^2 / \sigma_2^2} \sim F(n_1 - 1, n_2 - 1),$ 其中 $S_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (x_i - \bar{x})^2, \quad S_2^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (y_i - \bar{y})^2;$ $F(n_1 - 1, n_2 - 1)$ 表示第一自由度为 $n_1 - 1$，第二自由度为 $n_2 - 1$ 的 F 分布。
(3) 正态总体下分布的性质	$\bar{X}$ 与 S^2 独立。

<https://blog.csdn.net/xdy1120>

44、参数估计

矩估计

$F(x; \theta_1, \theta_2, \dots, \theta_m)$. 它的 k 阶原点矩 $v_k = E(X^k) (k=1, 2, \dots, m)$ 中也

包含了未知参数 $\theta_1, \theta_2, \dots, \theta_m$, 即 $v_k = v_k(\theta_1, \theta_2, \dots, \theta_m)$ 。又设

$x_1, x_2, \dots, x_n$ 为总体 X 的 n 个样本值, 其样本的 k 阶原点矩为

$$\frac{1}{n} \sum_{i=1}^n x_i^k \quad (k=1,2,\cdots,m).$$

这样，我们按照“当参数等于其估计量时，总体矩等于相应的样本矩”的原则建立方程，即有

$$\left\{ \begin{aligned} v_1(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m) &= \frac{1}{n} \sum_{i=1}^n x_i, \\ v_2(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m) &= \frac{1}{n} \sum_{i=1}^n x_i^2, \\ &\dots\dots\dots \\ v_m(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m) &= \frac{1}{n} \sum_{i=1}^n x_i^m. \end{aligned} \right.$$

由上面的 m 个方程中，解出的 m 个未知参数 $(\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m)$ 即为参数 $(\theta_1, \theta_2, \dots, \theta_m)$ 的矩估计量。

若 $\hat{\theta}$ 为 θ 的矩估计, $g(x)$ 为连续函数, 则 $g(\hat{\theta})$ 为 $g(\theta)$ 的矩估计.

极大似然估计	当总体 X 为连续型随机变量时，设其分布密度为 $f(x; \theta_1, \theta_2, \dots, \theta_m)$，其中 $\theta_1, \theta_2, \dots, \theta_m$ 为未知参数。又设 $x_1, x_2, \dots, x_n$ 为总体的一个样本，称 $L(\theta_1, \theta_2, \dots, \theta_m) = \prod_{i=1}^n f(x_i; \theta_1, \theta_2, \dots, \theta_m)$ 为样本的似然函数，简记为 L_n。 当总体 X 为离散型随机变量时，设其分布律为 $P\{X = x\} = p(x; \theta_1, \theta_2, \dots, \theta_m)$，则称 $L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_m) = \prod_{i=1}^n p(x_i; \theta_1, \theta_2, \dots, \theta_m)$ 为样本的似然函数。 若似然函数 $L(x_1, x_2, \dots, x_n; \theta_1, \theta_2, \dots, \theta_m)$ 在 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 处取到最大值，则称 $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_m$ 分别为 $\theta_1, \theta_2, \dots, \theta_m$ 的最大似然估计值，相应的统计量称为最大似然估计量。 $\left. \frac{\partial \ln L_n}{\partial \theta_i} \right _{\theta_i = \hat{\theta}_i} = 0, i = 1, 2, \dots, m$ 若 $\hat{\theta}$ 为 θ 的极大似然估计，$g(x)$ 为单调函数，则 $g(\hat{\theta})$ 为 $g(\theta)$ 的极大似然估计。 https://blog.csdn.net/xdy1120
(2) 估计量的评选标准	无偏性 设 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$ 为未知参数 θ 的估计量。若 $E(\hat{\theta}) = \theta$，则称 $\hat{\theta}$ 为 θ 的无偏估计量。 $E(\bar{X}) = E(X), E(S^2) = D(X)$ 有效性 设 $\hat{\theta}_1 = \hat{\theta}_1(x_1, x_2, \dots, x_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(x_1, x_2, \dots, x_n)$ 是未知参数 θ 的两个无偏估计量。若 $D(\hat{\theta}_1) < D(\hat{\theta}_2)$，则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效。 https://blog.csdn.net/xdy1120

一致性	设 $\hat{\theta}_n$ 是 θ 的一串估计量，如果对于任意的正数 ε，都有 $\lim_{n \rightarrow \infty} P(\hat{\theta}_n - \theta > \varepsilon) = 0,$ 则称 $\hat{\theta}_n$ 为 θ 的一致估计量（或相合估计量）。 若 $\hat{\theta}$ 为 θ 的无偏估计，且 $D(\hat{\theta}) \rightarrow 0 (n \rightarrow \infty)$，则 $\hat{\theta}$ 为 θ 的一致估计。 只要总体的 $E(X)$ 和 $D(X)$ 存在，一切样本矩和样本矩的连续函数都是相应总体的一致估计量。 https://blog.csdn.net/xdy1120
(3) 区间估计	置信区间和置信度 设总体 X 含有一个待估的未知参数 θ。如果我们从样本 $x_1, x_2, \dots, x_n$ 出发，找出两个统计量 $\theta_1 = \theta_1(x_1, x_2, \dots, x_n)$ 与 $\theta_2 = \theta_2(x_1, x_2, \dots, x_n)$ ($\theta_1 < \theta_2$)，使得区间 $[\theta_1, \theta_2]$ 以 $1 - \alpha$ ($0 < \alpha < 1$) 的概率包含这个待估参数 θ，即 $P\{\theta_1 \leq \theta \leq \theta_2\} = 1 - \alpha,$ 那么称区间 $[\theta_1, \theta_2]$ 为 θ 的置信区间，$1 - \alpha$ 为该区间的置信度（或置信水平）。
单正态总体的期望和方差的区间估计	设 $x_1, x_2, \dots, x_n$ 为总体 $X \sim N(\mu, \sigma^2)$ 的一个样本，在置信度为 $1 - \alpha$ 下，我们来确定 μ 和 σ^2 的置信区间 $[\theta_1, \theta_2]$。具体步骤如下： (i) 选择样本函数； (ii) 由置信度 $1 - \alpha$，查表找分位数； (iii) 导出置信区间 $[\theta_1, \theta_2]$。 https://blog.csdn.net/xdy1120

		已知方差，估计均值	(i) 选择样本函数 $u = \frac{\bar{x} - \mu}{\sigma_0 / \sqrt{n}} \sim N(0,1).$ (ii) 查表找分位数 $P\left(-\lambda \leq \frac{\bar{x} - \mu}{\sigma_0 / \sqrt{n}} \leq \lambda\right) = 1 - \alpha.$ (iii) 导出置信区间 $\left[\bar{x} - \lambda \frac{\sigma_0}{\sqrt{n}}, \bar{x} + \lambda \frac{\sigma_0}{\sqrt{n}}\right]$
		未知方差，估计均值	(i) 选择样本函数 $t = \frac{\bar{x} - \mu}{S / \sqrt{n}} \sim t(n-1).$ (ii) 查表找分位数 $P\left(-\lambda \leq \frac{\bar{x} - \mu}{S / \sqrt{n}} \leq \lambda\right) = 1 - \alpha.$ (iii) 导出置信区间 $\left[\bar{x} - \lambda \frac{S}{\sqrt{n}}, \bar{x} + \lambda \frac{S}{\sqrt{n}}\right]$
		方差的区间估计	(i) 选择样本函数 $w = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$ (ii) 查表找分位数 $P\left(\lambda_1 \leq \frac{(n-1)S^2}{\sigma^2} \leq \lambda_2\right) = 1 - \alpha.$ (iii) 导出 σ 的置信区间 $\left[\sqrt{\frac{n-1}{\lambda_2}} S, \sqrt{\frac{n-1}{\lambda_1}} S\right]$

45、假设检验

基本思想	假设检验的统计思想是，概率很小的事件在一次试验中可以认为基本上是不会发生的，即小概率原理。 为了检验一个假设 H_0 是否成立。我们先假定 H_0 是成立的。如果根据这个假定导致了一个不合理的事件发生，那就表明原来的假定 H_0 是不正确的，我们拒绝接受 H_0；如果由此没有导出不合理的现象，则不能拒绝接受 H_0，我们称 H_0 是相容的。与 H_0 相对的假设称为备择假设，用 H_1 表示。 这里所说的小概率事件就是事件 $\{K \in R_\alpha\}$，其概率就是检验水平 α，通常我们取 $\alpha = 0.05$，有时也取 0.01 或 0.10。
基本步骤	假设检验的基本步骤如下： (i) 提出零假设 H_0； (ii) 选择统计量 K； (iii) 对于检验水平 α 查表找分位数 λ； (iv) 由样本值 $x_1, x_2, \dots, x_n$ 计算统计量之值 K； 将 $\hat{K}$ 与 λ 进行比较，作出判断：当 $\hat{K} > \lambda$ (或 $\hat{K} > \lambda$) 时否定 H_0，否则认为 H_0 相容。 https://blog.csdn.net/xdy1120

两类错误	第一类错误	当 H_0 为真时，而样本值却落入了否定域，按照我们规定的检验法则，应当否定 H_0。这时，我们把客观上 H_0 成立判为 H_0 为不成立（即否定了真实的假设），称这种错误为“以真当假”的错误或第一类错误，记 α 为犯此类错误的概率，即 $P\{\text{否定 } H_0 H_0 \text{ 为真}\} = \alpha$； 此处的 α 恰好为检验水平。
	第二类错误	当 H_0 为真时，而样本值却落入了相容域，按照我们规定的检验法则，应当接受 H_0。这时，我们把客观上 H_0 不成立判为 H_0 成立（即接受了不真实的假设），称这种错误为“以假当真”的错误或第二类错误，记 β 为犯此类错误的概率，即 $P\{\text{接受 } H_0 H_0 \text{ 为真}\} = \beta$。
	两类错误的关系	人们当然希望犯两类错误的概率同时都很小。但是，当容量 n 一定时，α 变小，则 β 变大；相反地，β 变小，则 α 变大。取定 α 要想使 β 变小，则必须增加样本容量。 在实际使用时，通常人们只能控制犯第一类错误的概率，即给定显著性水平 α。α 大小的选取应根据实际情况而定。当我们宁可“以假为真”、而不愿“以真当假”时，则应把 α 取得很小，如 0.01，甚至 0.001。反之，则应把 α 取得大些。 https://blog.csdn.net/xdy1120

单正态总体均值和方差的假设检验

条件	零假设	统计量	对应样本函数分布	否定域
已知 σ^2	$H_0: \mu = \mu_0$	$U = \frac{\bar{x} - \mu_0}{\sigma_0 / \sqrt{n}}$	$N(0, 1)$	$ u > u_{1-\frac{\alpha}{2}}$
	$H_0: \mu \leq \mu_0$			$u > u_{1-\alpha}$
	$H_0: \mu \geq \mu_0$			$u < -u_{1-\alpha}$
未知 σ^2	$H_0: \mu = \mu_0$	$T = \frac{\bar{x} - \mu_0}{S / \sqrt{n}}$	$t(n-1)$	$ t > t_{1-\frac{\alpha}{2}}(n-1)$
	$H_0: \mu \leq \mu_0$			$t > t_{1-\alpha}(n-1)$
	$H_0: \mu \geq \mu_0$			$t < -t_{1-\alpha}(n-1)$
未知 σ^2	$H_0: \sigma^2 = \sigma_0^2$	$w = \frac{(n-1)S^2}{\sigma_0^2}$	$\chi^2(n-1)$	$w < \chi_{\frac{\alpha}{2}}^2(n-1)$ 或 $w > \chi_{1-\frac{\alpha}{2}}^2(n-1)$
	$H_0: \sigma^2 \leq \sigma_0^2$			$w > \chi_{1-\alpha}^2(n-1)$
	$H_0: \sigma^2 \geq \sigma_0^2$			$w < \chi_{\alpha}^2(n-1)$

https://blog.csdn.net/qq_41797007/article/details/1120